Universidad del Quindío
Programa de Ingeniería de Sistemas y Computación
Análisis de algoritmos en el contexto de la bibliometría
Descripción del seguimiento

1. Introducción

El estudio computacional de textos permite explorar y analizar volúmenes de datos derivados de la producción científica utilizando métodos cuantitativos y cualitativos. Se fundamenta en las matemáticas y la estadística, para establecer descripciones, relaciones, inferencias y presentaciones de la información suministrada por publicaciones científicas. En este contexto, la extracción de patrones, el análisis de similitud textual, la búsqueda, entre otros, resultan fundamentales. Para este proyecto, el dominio de conocimiento girará en torno a la inteligencia artificial generativa. Se busca que el estudiante enfrente el reto algorítmico de procesar lenguaje natural no estructurado, comprendiendo la transición matemática y lógica desde las estructuras de datos y algoritmos clásicos, hasta los modelos modernos implementados con Inteligencia Artificial (IA).

2. Fuentes de información

A diferencia de los procesos tradicionales de recolección automatizada sobre bases de datos científicas (tales como ACM, SAGE o ScienceDirect), para este proyecto se suministrará un corpus documental controlado y estático. La fuente de información consistirá en 20 artículos científicos entregados en formato PDF directamente por el docente. El procesamiento computacional y la implementación de los algoritmos se enfocarán de manera estricta y primordial sobre el abstract (resumen) de cada artículo. Los metadatos adicionales presentes en los documentos, específicamente el título del proyecto y los autores, serán extraídos y utilizados para requerimientos funcionales muy precisos que exijan el cruce de información.

3. Propósito del requerimiento - Ranking de términos mediante algoritmos de ordenamiento.

A partir del preprocesamiento de texto la aplicación deberá generar un listado ordenado de los términos más frecuentes del total de artículos, utilizando algoritmos de ordenamiento que no se basan en comparaciones directas entre elementos. Los siguientes son los algoritmos.

- Counting Sort
- Radix Sort
- Bucket Sort

El análisis del desempeño de los algoritmos de ordenamiento se debe presentar en el documento. Específicamente se requiere:

- Fundamentación teórica: Explicar por qué estos tres algoritmos logran complejidades asintóticas de $O(n+k)$ u $O(n)$

- Medición empírica: Ejecutar los tres algoritmos implementados sobre la lista de frecuencias de palabras extraída del corpus completo. Se deben medir los tiempos reales de ejecución en milisegundos.

- Validación de resultados: Presentar una tabla o gráfico de los 15 términos más frecuentes del corpus, obtenidos mediante cada uno de los tres algoritmos.